UNIVERSIDADE ESTADUAL PAULISTA
"JÚLIO DE MESQUITA FILHO"
Instituto de Geociências e Ciências Exatas - IGCE
Curso de Bacharelado em Ciências da Computação

GABRIEL LUIZ

TRABALHO DE CLASSIFICAÇÃO

Professora: Dra. Adriane Beatriz de Souza Serapião

Rio Claro - SP

2020

1 Introdução

Este trabalho consiste em aplicar o conhecimento de clustering adquirido na disciplina Tópicos: Aprendizado de Máquina, tendo assim como objetivo:

- Escolha dois datasets rotulados.
- Realize a análise estatística, visualização e pré-processamento dos dados.
- Realize os experimentos criando duas bases de teste distintas:

  considerando todos os atributos do dataset;

  selecionando alguns atributos e descartando outros.
- Aplique três métodos de classificação distintos nas duas bases acima referentes a cada dataset.
- Para cada dataset, em cada uma das bases, analise os resultados segundo medidas de qualidade de classificação, usando índices de validação externa (acurácia, recall, precisão, F-measure, índice Kappa) e cruva ROC.
- Proponha uma maneira adicional de comparar os resultados obtidos além das medidas acima.
- Compare e interprete os resultados dos dois experimentos em cada dataset. Faça tabela com as medidas de validação

2 Desenvolvimento

Para o desenvolvimento das atividades inicialmente foi escolhido duas base de dados. As bases foram encontradas no site http://cs.uef.fi/sipu/datasets/ onde possuem datasets próprios para a tarefa de clustering, os dataset não possuem informações de que se referem cada atributo ou cada instancia.

2.1 Pré-processamento e Visualização

Para realizar o pré-processamento foi necessário validar se os dados não possuiam números vazios ou algum tipo de valor que foge do esperado.

2.2 Validação dos dados

Foi validado que os dataset não possuem nenhum valor nulo ou valores diferentes de inteiro maior do que zero.

2.3 Análise dos dados

Com os valores todos normalizados podemos ver a correlação entre os atributos, que possuem alta relação em alguns casos. 1

Após a visualazação dos dados foi gerado o bloxpot 3 para ver como está a distribuição dos dados onde é possível ver que poucos atributos possuem outliers e os dados possuem certa distribuição padrão, e também os valores de media, moda e mediana para cada atributo.2

2.4 Escalonamento

Para aplicar os algoritmos de clustering, é necessário escalonar os dados, normalizando eles em uma faixa de -1 a 1, onde os dados irão manter a mesma proporção e similaridades.

2.5 Seleção de atributos

Após executar os três algoritmos de classificação com o dataset em questão, foi realizado um processo de seleção de atributos para realizar novamente a execução destes

	0	1	2	3	4	5	6	7	8	9	...	22	23	24
0	1.000000	0.268198	-0.051122	-0.068849	0.599398	-0.438830	0.041834	0.122806	0.140755	0.017996	...	0.298212	0.022004	0.193500
1	0.268198	1.000000	-0.434193	0.065247	0.147223	-0.087154	0.052960	0.112432	0.227755	0.442574	...	0.218035	-0.323157	0.388152
2	-0.051122	-0.434193	1.000000	-0.212930	0.077845	0.065985	-0.022429	-0.216804	-0.180707	-0.143382	...	0.142550	-0.167976	-0.479971
3	-0.068849	0.065247	-0.212930	1.000000	-0.049977	-0.004621	0.348210	0.042810	0.093820	0.186358	...	0.056818	0.125137	0.050242
4	0.599398	0.147223	0.077845	-0.049977	1.000000	-0.512794	-0.189263	0.334837	0.483320	0.257335	...	0.427911	-0.102514	0.071684
5	-0.438830	-0.087154	0.065985	-0.004621	-0.512794	1.000000	0.549921	-0.635187	-0.236149	-0.517697	...	0.125967	-0.170035	0.165715
6	0.041834	0.052960	-0.022429	0.348210	-0.189263	0.549921	1.000000	-0.410581	-0.194464	-0.334774	...	0.240729	-0.315245	0.261003
7	0.122806	0.112432	-0.216804	0.042810	0.334837	-0.635187	-0.410581	1.000000	0.546772	0.702223	...	-0.178068	0.247391	0.277945
8	0.140755	0.227755	-0.180707	0.093820	0.483320	-0.236149	-0.194464	0.546772	1.000000	0.271853	...	-0.024533	0.151648	0.257148
9	0.017996	0.442574	-0.143382	0.186358	0.257335	-0.517697	-0.334774	0.702223	0.271853	1.000000	...	0.087693	-0.236956	0.198970
10	-0.416168	-0.247372	-0.078198	-0.256024	-0.421847	0.422388	0.085398	-0.092287	-0.240591	-0.328448	...	-0.033714	0.088643	0.031608
11	-0.325456	0.049006	-0.005908	-0.023452	-0.093708	0.000218	-0.346374	0.120182	0.052129	0.429568	...	0.142397	-0.407174	-0.075290
12	0.149802	-0.101557	-0.327047	0.109485	0.133371	-0.173939	0.251279	0.409645	0.260425	0.078683	...	-0.473271	0.256056	0.430193
13	0.494533	0.135398	-0.275698	0.165248	0.393054	-0.037131	0.037670	0.161548	0.404304	0.132367	...	0.173041	0.090210	0.280425
14	0.054404	0.253658	0.027675	0.226054	0.026300	0.018823	0.180490	-0.027761	0.383065	-0.032232	...	-0.243979	0.092168	0.168610
15	-0.029940	-0.281726	-0.376820	-0.159598	-0.033689	-0.125013	0.108979	0.221851	-0.183596	-0.171017	...	-0.164908	0.150529	0.192498
16	0.076611	-0.338553	0.435520	-0.105110	0.021825	0.339884	0.230447	-0.337374	-0.054222	-0.653484	...	-0.010527	0.264512	-0.244634
17	-0.302741	-0.274373	0.298525	-0.188220	-0.401813	0.141096	-0.093745	-0.366459	-0.809519	-0.130695	...	0.146363	0.046578	-0.353528
18	0.527674	0.629009	-0.384632	0.489437	0.561829	-0.389271	0.212298	0.233610	0.380397	0.387718	...	0.400243	-0.182152	0.287166
19	0.320353	-0.094752	0.120599	0.444076	0.131633	-0.174375	0.417336	0.085567	-0.114620	0.213432	...	0.440008	-0.035431	0.041517
20	-0.479669	-0.452581	0.081423	0.053097	-0.336928	0.405705	0.502963	-0.158576	-0.371150	-0.320810	...	-0.065699	-0.132771	0.109687
21	0.148475	0.161413	-0.386965	-0.059567	0.288114	-0.083627	-0.269380	-0.064146	0.156344	-0.158748	...	-0.110877	0.414004	0.017234
22	0.298212	0.218035	0.142550	0.056818	0.427911	0.125967	0.240729	-0.178068	-0.024533	0.087693	...	1.000000	-0.369970	-0.059085
23	0.022004	-0.323157	-0.167976	0.125137	-0.102514	-0.170035	-0.315245	0.247391	0.151648	-0.236956	...	-0.369970	1.000000	0.069852
24	0.193500	0.388152	-0.479971	0.050242	0.071684	0.165715	0.261003	0.277945	0.257148	0.198970	...	-0.059085	0.069852	1.000000
25	-0.007820	-0.007483	-0.183073	-0.082015	0.042287	-0.463263	-0.589061	0.474793	0.219656	0.278513	...	-0.624774	0.399422	0.221850
26	-0.391960	-0.222688	0.094760	-0.042200	-0.246345	-0.138948	-0.626816	0.290873	0.184472	0.186412	...	-0.701118	0.442418	-0.092619
27	0.478101	0.224718	-0.298575	-0.079141	0.260857	0.029176	0.142038	-0.147543	0.315283	-0.334449	...	-0.193228	0.013597	0.388245
28	-0.658871	0.126030	0.080989	0.141606	-0.326250	0.013689	-0.162874	-0.145856	-0.126491	0.165812	...	-0.079521	-0.058917	-0.264124
29	0.275498	0.268201	-0.458842	0.276326	0.085673	-0.169076	0.393038	0.229722	0.228800	-0.066543	...	-0.320609	0.253746	0.468917
30	-0.166015	-0.014487	0.172647	0.313186	0.004851	0.132724	0.493069	0.120050	-0.127096	0.323513	...	0.285268	-0.297381	0.211759

Figura 1 – Correlação entre os dados.
Fonte: pessoal.

	0	1	2	3	4	5	6	7	8	9
count	1024.000000	1024.000000	1024.000000	1024.000000	1024.000000	1024.000000	1024.000000	1024.000000	1024.000000	1024.000000
mean	95.626953	109.116211	112.750000	127.612305	139.097656	130.491211	142.145508	134.344727	97.023438	135.126953
std	33.615901	56.908917	51.135914	48.141948	59.470162	39.287918	45.671907	59.378414	42.142075	66.366363
min	30.000000	40.000000	40.000000	41.000000	28.000000	48.000000	48.000000	25.000000	24.000000	29.000000
25%	73.000000	56.000000	72.000000	81.750000	88.000000	104.000000	106.000000	79.000000	63.000000	58.500000
50%	88.500000	97.000000	97.000000	142.000000	169.000000	129.000000	159.000000	145.000000	85.000000	169.500000
75%	121.000000	145.000000	168.000000	162.000000	186.000000	150.000000	171.000000	188.750000	134.750000	187.000000
max	162.000000	219.000000	217.000000	217.000000	218.000000	225.000000	220.000000	229.000000	174.000000	222.000000

Figura 2 – Distribuição dos dados.
Fonte: pessoal.

mesmos algoritmos.

O dataset possuia 32 atributos numericos, para realizar a selação foi utilizado um algoritmo que utiliza um parametro k como score para selecionar os melhores atributos.

Neste dataset o algoritmo selecionou apenas 4 atributos

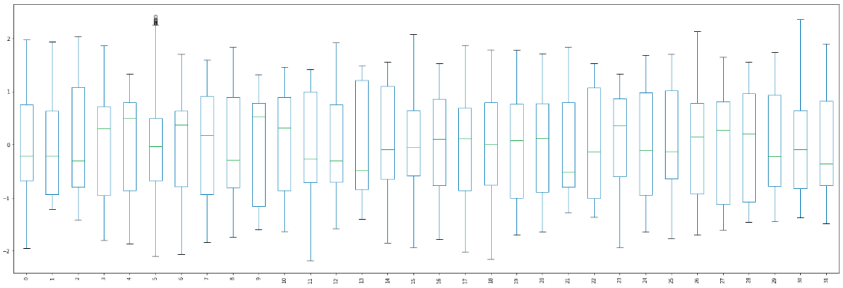

Figura 3 – Bloxpot exibindo outliers.
Fonte: pessoal.

dim032-classification

August 19, 2020

1 0. Introdução

Trabalho Clustering:

Aluno: Gabriel Luiz

Disciplina: Tópico em Aprendizado de Máquina

Objetivos :

- Escolha dois datasets rotulados.
- Realize a análise estatística, visualização e pré-processamento dos dados.
- Realize os experimentos criando duas bases de teste distintas:
- – considerando todos os atributos do dataset;
- – selecionando alguns atributos e descartando outros.
- Aplique três métodos de classificação distintos nas duas bases acima referentes a cada dataset.
- Para cada dataset, em cada uma das bases, analise os resultados segundo medidas de qualidade de classificação, usando índices de validação externa (acurácia, recall, precisão, F-measure, índice Kappa) e cruva ROC.
- Proponha uma maneira adicional de comparar os resultados obtidos além das medidas acima.
- Compare e interprete os resultados dos dois experimentos em cada dataset. Faça tabela com as medidas de validação

1.1 0.1 Dependências

Para realização da tarefa foram utilizados as seguintes bibliotecas:

[202]:
```
from datetime import datetime
import numpy as np
import pandas as pd
from sklearn.cluster import *
import seaborn as sns
from sklearn.preprocessing import StandardScaler
import matplotlib.pyplot as plt
from sklearn.feature_selection import SelectKBest
```

```
from sklearn.feature_selection import chi2
from sklearn.model_selection import train_test_split

# KFold
from sklearn.model_selection import KFold
import random

# Classificadores
from sklearn.neighbors import KNeighborsClassifier
from sklearn.naive_bayes import GaussianNB
from sklearn.tree import DecisionTreeClassifier
from sklearn.svm import SVC

#Metricas
from sklearn.metrics import accuracy_score
from sklearn.metrics import recall_score
from sklearn.metrics import precision_score
from sklearn.metrics import f1_score
from sklearn.metrics import cohen_kappa_score
from  sklearn.metrics  import  roc_auc_score
from sklearn.metrics import balanced_accuracy_score
```

2 1. Dados

Para realização das tarefas envolvidas neste relatório utilizou-se o arquivo **dim032.csv** que contém dados não descritos, onde foram feitos para a realização de clustering que se encontram no site: http://cs.uef.fi/sipu/datasets/

2.1 1.1 Carregamento do arquivo

[203]:
```
from clustering.labelMatch import rotulos, labelmatch
dataset = './dataset/dim032/dim032.csv'
clusters = './dataset/dim032/dim032-pa.csv'
```

[204]:
```
data = pd.read_csv(
    dataset,
    header = None
    )

label = pd.read_csv(
    clusters,
    header = None
    )
```

[205]:
```
data.head()
```

[205]:

```
   0    1    2   3    4    5    6    7   8    9   …   22  23   24   25  26  \
0  84  152  100  52   95  186  169  106  37  186  …  190  65  214  116  75
1  86  149  101  56   93  181  171  116  37  192  …  191  79  215  116  76
2  83  149   99  51   96  187  169  108  34  191  …  190  65  213  118  73
3  86  142  101  64  105  183  172  116  49  180  …  186  69  209  120  68
4  89  145  108  54   91  180  175  107  35  192  …  188  67  212  118  91

   27   28  29   30   31
0  55  123  65  154  177
1  60  130  71  151  181
2  55  125  63  155  178
3  56  123  67  144  181
4  50  135  58  147  165

[5 rows x 32 columns]
```

[206]:
```
data.describe()
```

[206]:

```
                0            1            2            3            4   \
count  1024.000000  1024.000000  1024.000000  1024.000000  1024.000000
mean     95.626953   109.116211   112.750000   127.612305   139.097656
std      33.615901    56.908917    51.135914    48.141948    59.470162
min      30.000000    40.000000    40.000000    41.000000    28.000000
25%      73.000000    56.000000    72.000000    81.750000    88.000000
50%      88.500000    97.000000    97.000000   142.000000   169.000000
75%     121.000000   145.000000   168.000000   162.000000   186.000000
max     162.000000   219.000000   217.000000   217.000000   218.000000

                5            6            7            8            9   …  \
count  1024.000000  1024.000000  1024.000000  1024.000000  1024.000000  …
mean    130.491211   142.145508   134.344727    97.023438   135.126953  …
std      39.287918    45.671907    59.378414    42.142075    66.366363  …
min      48.000000    48.000000    25.000000    24.000000    29.000000  …
25%     104.000000   106.000000    79.000000    63.000000    58.500000  …
50%     129.000000   159.000000   145.000000    85.000000   169.500000  …
75%     150.000000   171.000000   188.750000   134.750000   187.000000  …
max     225.000000   220.000000   229.000000   174.000000   222.000000  …

               22           23           24           25           26  \
count  1024.000000  1024.000000  1024.000000  1024.000000  1024.000000
mean    120.544922   154.849609   123.900391   123.157227   105.608398
std      67.089616    60.070835    58.308579    55.723743    48.049909
min      29.000000    39.000000    28.000000    25.000000    24.000000
25%      53.000000   118.750000    69.000000    87.500000    61.000000
50%     111.500000   176.000000   117.500000   116.000000   113.000000
```

```
75%     192.000000   207.000000   181.000000   179.750000   143.250000
max     223.000000   235.000000   222.000000   218.000000   208.000000

                27           28           29           30           31
count  1024.000000  1024.000000  1024.000000  1024.000000  1024.000000
mean    122.179688   130.062500   130.897461   106.218750   116.990234
std      58.800397    61.676195    55.330114    47.630102    55.882102
min      28.000000    40.000000    51.000000    41.000000    34.000000
25%      56.000000    64.000000    88.000000    67.000000    74.000000
50%     138.000000   143.000000   118.500000   102.000000    97.000000
75%     169.750000   189.000000   182.250000   136.750000   162.750000
max     219.000000   226.000000   227.000000   218.000000   223.000000

[8 rows x 32 columns]
```

[ ]:
```
# 2. Pré-processamento
```

Validações efetivadas:

- 1. Dados faltantes representados por "NaN"
- 2. Dados que não possuem valores númericos

[207]:
```
# data.isna().sum()
```

[208]:
```
# for col in data:
    # print(col, data[col].unique())
```

2.1 Conclusão:

- Os dados não possuem a necessidade de pré-processamento visto que já estão todos com valores validos

2.1.1 2.3 Análise estatística

[209]:
```
data.corr()
```

[209]:
```
          0         1         2         3         4         5         6   \
0   1.000000  0.268198 -0.051122 -0.068849  0.599398 -0.438830  0.041834
1   0.268198  1.000000 -0.434193  0.065247  0.147223 -0.087154  0.052960
2  -0.051122 -0.434193  1.000000 -0.212930  0.077845  0.065985 -0.022429
3  -0.068849  0.065247 -0.212930  1.000000 -0.049977 -0.004621  0.348210
4   0.599398  0.147223  0.077845 -0.049977  1.000000 -0.512794 -0.189263
5  -0.438830 -0.087154  0.065985 -0.004621 -0.512794  1.000000  0.549921
6   0.041834  0.052960 -0.022429  0.348210 -0.189263  0.549921  1.000000
7   0.122806  0.112432 -0.216804  0.042810  0.334837 -0.635187 -0.410581
```

```
8   0.140755  0.227755 -0.180707  0.093820  0.483320 -0.236149 -0.194464
9   0.017996  0.442574 -0.143382  0.186358  0.257335 -0.517697 -0.334774
10 -0.416168 -0.247372 -0.078198 -0.256024 -0.421847  0.422388  0.085398
11 -0.325456  0.049006 -0.005908 -0.023452 -0.093708  0.000218 -0.346374
12  0.149802 -0.101557 -0.327047  0.109485  0.133371 -0.173939  0.251279
13  0.494533  0.135398 -0.275698  0.165248  0.393054 -0.037131  0.037670
14  0.054404  0.253658  0.027675  0.226054  0.026300  0.018823  0.180490
15 -0.029940 -0.281726 -0.376820 -0.159598 -0.033689 -0.125013  0.108979
16  0.076611 -0.338553  0.435520 -0.105110  0.021825  0.339884  0.230447
17 -0.302741 -0.274373  0.298525 -0.188220 -0.401813  0.141096 -0.093745
18  0.527674  0.629009 -0.384632  0.489437  0.561829 -0.389271  0.212298
19  0.320353 -0.094752  0.120599  0.444076  0.131633 -0.174375  0.417336
20 -0.479669 -0.452581  0.081423  0.053097 -0.336928  0.405705  0.502963
21  0.148475  0.161413 -0.386965 -0.059567  0.288114 -0.083627 -0.269380
22  0.298212  0.218035  0.142550  0.056818  0.427911  0.125967  0.240729
23  0.022004 -0.323157 -0.167976  0.125137 -0.102514 -0.170035 -0.315245
24  0.193500  0.388152 -0.479971  0.050242  0.071684  0.165715  0.261003
25 -0.007820 -0.007483 -0.183073 -0.082015  0.042287 -0.463263 -0.589061
26 -0.391960 -0.222688  0.094760 -0.042200 -0.246345 -0.138948 -0.626816
27  0.478101  0.224718 -0.298575 -0.079141  0.260857  0.029176  0.142038
28 -0.658871  0.126030  0.080989  0.141606 -0.326250  0.013689 -0.162874
29  0.275498  0.268201 -0.458842  0.276326  0.085673 -0.169076  0.393038
30 -0.166015 -0.014487  0.172647  0.313186  0.004851  0.132724  0.493069
31  0.234555  0.132197 -0.408891 -0.219960  0.082626  0.028978  0.155258

          7         8         9   …        22        23        24        25  \
0   0.122806  0.140755  0.017996  …  0.298212  0.022004  0.193500 -0.007820
1   0.112432  0.227755  0.442574  …  0.218035 -0.323157  0.388152 -0.007483
2  -0.216804 -0.180707 -0.143382  …  0.142550 -0.167976 -0.479971 -0.183073
3   0.042810  0.093820  0.186358  …  0.056818  0.125137  0.050242 -0.082015
4   0.334837  0.483320  0.257335  …  0.427911 -0.102514  0.071684  0.042287
5  -0.635187 -0.236149 -0.517697  …  0.125967 -0.170035  0.165715 -0.463263
6  -0.410581 -0.194464 -0.334774  …  0.240729 -0.315245  0.261003 -0.589061
7   1.000000  0.546772  0.702223  … -0.178068  0.247391  0.277945  0.474793
8   0.546772  1.000000  0.271853  … -0.024533  0.151648  0.257148  0.219656
9   0.702223  0.271853  1.000000  …  0.087693 -0.236956  0.198970  0.278513
10 -0.092287 -0.240591 -0.328448  … -0.033714  0.088643  0.031608 -0.376352
11  0.120182  0.052129  0.429568  …  0.142397 -0.407174 -0.075290  0.217259
12  0.409645  0.260425  0.078683  … -0.473271  0.256056  0.430193  0.171557
13  0.161548  0.404304  0.132367  …  0.173041  0.090210  0.280425 -0.214557
14 -0.027761  0.383065 -0.032232  … -0.243979  0.092168  0.168610  0.326534
15  0.221851 -0.183596 -0.171017  … -0.164908  0.150529  0.192498 -0.069413
16 -0.337374 -0.054222 -0.653484  … -0.010527  0.264512 -0.244634 -0.393127
17 -0.366459 -0.809519 -0.130695  …  0.146363  0.046578 -0.353528 -0.293029
18  0.233610  0.380397  0.387718  …  0.400243 -0.182152  0.287166 -0.171046
19  0.085567 -0.114620  0.213432  …  0.440008 -0.035431  0.041517 -0.244667
20 -0.158576 -0.371150 -0.320810  … -0.065699 -0.132771  0.109687 -0.225979
```

```
21 -0.064146  0.156344 -0.158748  … -0.110877  0.414004  0.017234  0.157122
22 -0.178068 -0.024533  0.087693  …  1.000000 -0.369970 -0.059085 -0.624774
23  0.247391  0.151648 -0.236956  … -0.369970  1.000000  0.069852  0.399422
24  0.277945  0.257148  0.198970  … -0.059085  0.069852  1.000000  0.221850
25  0.474793  0.219656  0.278513  … -0.624774  0.399422  0.221850  1.000000
26  0.290873  0.184472  0.186412  … -0.701118  0.442418 -0.092619  0.698714
27 -0.147543  0.315283 -0.334449  … -0.193228  0.013597  0.388245 -0.020877
28 -0.145856 -0.126491  0.165812  … -0.079521 -0.058917 -0.264124  0.123476
29  0.229722  0.228800 -0.066543  … -0.320609  0.253746  0.468917  0.079350
30  0.120050 -0.127096  0.323513  …  0.285268 -0.297381  0.211759 -0.357671
31 -0.121036 -0.001655 -0.220399  … -0.163059  0.283402  0.306188  0.149484

          26        27        28        29        30        31
0  -0.391960  0.478101 -0.658871  0.275498 -0.166015  0.234555
1  -0.222688  0.224718  0.126030  0.268201 -0.014487  0.132197
2   0.094760 -0.298575  0.080989 -0.458842  0.172647 -0.408891
3  -0.042200 -0.079141  0.141606  0.276326  0.313186 -0.219960
4  -0.246345  0.260857 -0.326250  0.085673  0.004851  0.082626
5  -0.138948  0.029176  0.013689 -0.169076  0.132724  0.028978
6  -0.626816  0.142038 -0.162874  0.393038  0.493069  0.155258
7   0.290873 -0.147543 -0.145856  0.229722  0.120050 -0.121036
8   0.184472  0.315283 -0.126491  0.228800 -0.127096 -0.001655
9   0.186412 -0.334449  0.165812 -0.066543  0.323513 -0.220399
10 -0.179221 -0.058145 -0.051353  0.065142 -0.060821 -0.216716
11  0.137810 -0.437226  0.259213 -0.526618 -0.172597 -0.439803
12  0.094848  0.344143 -0.423074  0.692584  0.200866  0.511520
13 -0.067142  0.508689 -0.684955  0.144636 -0.021558  0.228797
14  0.289699  0.241383  0.249653  0.154281  0.139658  0.214654
15 -0.244122  0.184142 -0.206692  0.347151  0.203000  0.091169
16 -0.020745  0.313308 -0.291156  0.051421  0.019573 -0.032069
17 -0.079840 -0.493866  0.325377 -0.354793  0.128913 -0.114960
18 -0.470166  0.358691 -0.076450  0.453114  0.222688  0.016510
19 -0.368946 -0.257975 -0.060471 -0.023146  0.636369 -0.017978
20 -0.251045 -0.177907  0.147623  0.103378  0.483521 -0.185867
21  0.138043  0.250837 -0.137726  0.282940 -0.534742  0.646400
22 -0.701118 -0.193228 -0.079521 -0.320609  0.285268 -0.163059
23  0.442418  0.013597 -0.058917  0.253746 -0.297381  0.283402
24 -0.092619  0.388245 -0.264124  0.468917  0.211759  0.306188
25  0.698714 -0.020877  0.123476  0.079350 -0.357671  0.149484
26  1.000000 -0.114451  0.229124 -0.243960 -0.226023 -0.060403
27 -0.114451  1.000000 -0.466836  0.431696 -0.227496  0.233082
28  0.229124 -0.466836  1.000000 -0.220608  0.153451 -0.178395
29 -0.243960  0.431696 -0.220608  1.000000 -0.038159  0.414073
30 -0.226023 -0.227496  0.153451 -0.038159  1.000000 -0.191372
31 -0.060403  0.233082 -0.178395  0.414073 -0.191372  1.000000

[32 rows x 32 columns]
```

[210]:
```
df = data
df = df.assign(label = label)
test = df[[0, 1, 2, 3, 'label']]
test
```

[210]:

	0	1	2	3	label
0	84	152	100	52	1
1	86	149	101	56	1
2	83	149	99	51	1
3	86	142	101	64	1
4	89	145	108	54	1
…	…	…	…	..	…
1019	105	53	168	77	16
1020	104	53	169	77	16
1021	101	52	171	78	16
1022	106	59	165	74	16
1023	105	53	168	77	16

[1024 rows x 5 columns]

[ ]:
```
sns.pairplot(df, diag_kind="kde",hue='label')
```

[ ]: <seaborn.axisgrid.PairGrid at 0x7fdd8a9bc710>

[211]:
```
sns.pairplot(test, diag_kind="kde",hue='label')
```

[211]: <seaborn.axisgrid.PairGrid at 0x7fdd90af52e8>

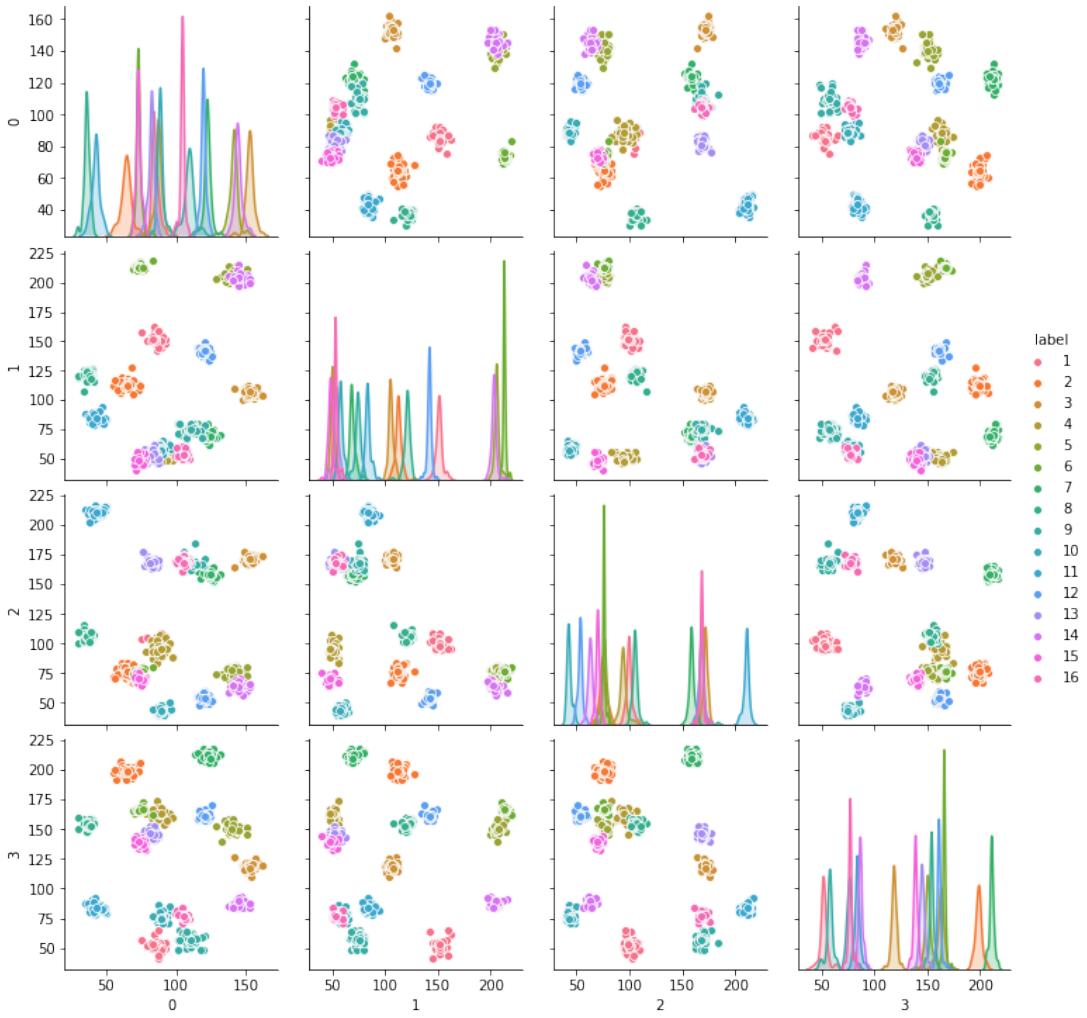

2.1.2 2.4 Escalonando

Para aplicação dos algoritmos escalona-se os dados afim de parametriza-los num certo intervalor (-1 a 1)

[212]:
```
data = data.to_numpy()
scaler = StandardScaler().fit(data)
data_scaler = scaler.transform(data)
```

[213]:
```
# data_scaled = pd.DataFrame(data_scaler)
# data_scaled.head()
```

[214]:
```
data_results = np.array(label[0].tolist())
for idx, value in np.ndenumerate(data_results):
```

```
    data_results[idx] = value - 1
```

2.1.3 2.5 Plotando boxsplot

Pelo boxsplot é possivel visualizar que há alguns outliers.

[215]:
```
# data_scaled.plot(kind = 'box', figsize=(30,10), rot=90, )
```

2.2 3.2 Selecionando atributos do dataset

[216]:
```
data_reduzida = pd.DataFrame(SelectKBest(chi2, k=30).fit_transform(data, label))
data_reduzida.shape
data_reduzida = data_reduzida.to_numpy()

data_scaler2 = scaler.fit_transform(X = data_reduzida)
```

[217]:
```
# data_scaled2 = pd.DataFrame(data_scaler2)
# data_scaled2.head()
```

2.3 Classificando

2.4 Funções necessárias

[218]:
```
def calcula_metricas(metricas, y_test, y_predict):
    metricas['acc'] += (accuracy_score(y_test, y_predict))
    metricas['recall'] += (recall_score(y_test, y_predict, average='micro'))
    metricas['precision'] += (precision_score(y_test, y_predict,␣
 ↪average='macro'))
    metricas['f1'] += f1_score(y_test, y_predict, average='weighted')
    # metricas['roc'] += roc_auc_score(y_test, y_predict)
    metricas['kappa'] += cohen_kappa_score(y_test, y_predict)
    metricas['balanced_acc'] += balanced_accuracy_score(y_test, y_predict)
```

[219]:
```
def save_metricas(name, metricas):
    f = open(name, 'w')
    f.write('Acuária:' + str(metricas['acc']) + '\n')
    f.write('Recall:' + str(metricas['recall']) + '\n')
    f.write('Precisão:' + str(metricas['precision']) + '\n')
    f.write('F-Measure:' + str(metricas['f1']) + '\n')
    # f.write('Curva Roc:' + str(metricas['roc']) + '\n')
    f.write('Indice Kappa:' + str(metricas['kappa']) + '\n')
    f.write('Acuária Balanceada:' + str(metricas['balanced_acc']) + '\n')
    f.close()
```

[220]:
```
def show_metricas(metricas):
    print('Acuária:', metricas['acc'])
    print('Recall:', metricas['recall'])
    print('Precisão:', metricas['precision'])
    print('F-Measure:', metricas['f1'])
    # print('Curva Roc:', metricas['roc'])
    print('Indice Kappa:', metricas['kappa'])
    print('Acuária Balanceada:', metricas['balanced_acc'])
```

[221]:
```
def write_metricas(name_file, metricas, metodo):
    f = open(name_file, "a")
    f.write(metodo + ',')
    f.write(str(round(metricas['acc'],4)) + ',')
    f.write(str(round(metricas['recall'],4)) + ',')
    f.write(str(round(metricas['precision'],4)) + ',')
    f.write(str(round(metricas['f1'],4)) + ',')
    # f.write(str(round(metricas['roc'],4)) + ';')
    f.write(str(round(metricas['kappa'],4)) + ',')
    f.write(str(round(metricas['balanced_acc'],4)) + '\n')
    f.close()
```

2.5 Aplicando KNN com K-fold

2.6 DataFrame Cru

[222]:
```
formato = 'Cru'

folds_value = 16
```

[223]:
```
# TODO change split function
kf = KFold(n_splits=2, shuffle=True, random_state=random.randint(0, 10))
data_kfold = kf.split(data)

train = []
test = []

for train_index, test_index in data_kfold:
    train.append(train_index)
    test.append(test_index)
```

[224]:
```
name_file = 'metricas.csv'

# Roc;
f = open(name_file, "w")
f.write('Acurácia,Recall,Precisão,F1,Kappa,Acurácia Balanceada\n')
f.close()
```

2.7 Aplicando KNN com K-fold

[225]:
```
# 'roc': 0,
metodo = 'KNN'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'kappa': 0,␣
 ↪'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

neigh = KNeighborsClassifier(n_neighbors=10)
neigh.fit(x_train, y_train)

y_predict = neigh.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 1.0
Recall: 1.0
Precisão: 1.0
F-Measure: 1.0
Indice Kappa: 1.0
Acuária Balanceada: 1.0
```

[226]:
```
# # 'roc': 0,
# metodo = 'KNN'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'kappa': 0,␣
 ↪'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler[train_index], data_scaler[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     neigh = KNeighborsClassifier(n_neighbors=100)
#     neigh.fit(x_train, y_train)
#
#     y_predict = neigh.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

2.8 Aplicando GaussianNB com K-fold

[227]:
```
metodo = 'Gauss'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
 ↪0, 'balanced_acc': 0}


x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

gauss = GaussianNB()
gauss.fit(x_train, y_train)

y_predict = gauss.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 1.0
Recall: 1.0
Precisão: 1.0
F-Measure: 1.0
Indice Kappa: 1.0
Acuária Balanceada: 1.0
```

[228]:
```
# metodo = 'Gauss'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
 ↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler[train_index], data_scaler[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     gauss = GaussianNB()
#     gauss.fit(x_train, y_train)
#
#     y_predict = gauss.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

2.9 Aplicando DecisionTreeClassifier com K-fold

[229]:
```
metodo = 'Tree'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
↪0, 'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

tree = DecisionTreeClassifier()
tree.fit(x_train, y_train)

y_predict = tree.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 0.9921875
Recall: 0.9921875
Precisão: 0.9930555555555556
F-Measure: 0.9922002655228759
Indice Kappa: 0.9916421808684296
Acuária Balanceada: 0.993421052631579
```

[230]:
```
# metodo = 'Tree'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler[train_index], data_scaler[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     tree = DecisionTreeClassifier()
#     tree.fit(x_train, y_train)
#
#     y_predict = tree.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

2.10 Aplicando SVM com K-fold

[231]:
```
metodo = 'SVM'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
↪0, 'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

svm = SVC()
svm.fit(x_train, y_train)

y_predict = svm.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 1.0
Recall: 1.0
Precisão: 1.0
F-Measure: 1.0
Indice Kappa: 1.0
Acuária Balanceada: 1.0
```

[232]:
```
# metodo = 'SVM'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler[train_index], data_scaler[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     svm = SVC()
#     svm.fit(x_train, y_train)
#
#     y_predict = svm.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

2.11 DataFrame Selecionado

2.12 Aplicando

[233]:
```
kf = KFold(n_splits=2, shuffle=True, random_state=random.randint(0, 10))
data_kfold = kf.split(data_scaler2)

train = []
test = []

for train_index, test_index in data_kfold:
    train.append(train_index)
    test.append(test_index)
```

2.13 Aplicando KNN com K-fold

[234]:
```
metodo = 'KNNSELECT'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
 ↪0, 'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

neigh = KNeighborsClassifier(n_neighbors=10)
neigh.fit(x_train, y_train)

y_predict = neigh.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 1.0
Recall: 1.0
Precisão: 1.0
F-Measure: 1.0
Indice Kappa: 1.0
Acuária Balanceada: 1.0
```

[235]:
```
# metodo = 'KNNSELECT'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
 ↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler2[train_index], data_scaler2[test_index]
```

```
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     neigh = KNeighborsClassifier(n_neighbors=20)
#     neigh.fit(x_train, y_train)
#
#     y_predict = neigh.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

2.14 Aplicando GaussianNB com K-fold

[236]:
```
metodo = 'GaussSELECT'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
↪0, 'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

gauss = GaussianNB()
gauss.fit(x_train, y_train)

y_predict = gauss.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 1.0
Recall: 1.0
Precisão: 1.0
F-Measure: 1.0
Indice Kappa: 1.0
Acuária Balanceada: 1.0
```

[237]:
```
# metodo = 'GaussSELECT'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler2[train_index], data_scaler2[test_index]
```

```
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     gauss = GaussianNB()
#     gauss.fit(x_train, y_train)
#
#     y_predict = gauss.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

2.15 Aplicando DecisionTreeClassifier com K-fold

[238]:
```
metodo = 'TreeSELECT'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
↪0, 'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

tree = DecisionTreeClassifier()
tree.fit(x_train, y_train)

y_predict = tree.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 0.984375
Recall: 0.984375
Precisão: 0.9844909750337382
F-Measure: 0.9845306385931386
Indice Kappa: 0.9832720738381115
Acuária Balanceada: 0.984046743697479
```

[239]:
```
# metodo = 'TreeSELECT'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler2[train_index], data_scaler2[test_index]
```

```
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     tree = DecisionTreeClassifier()
#     tree.fit(x_train, y_train)
#
#     y_predict = tree.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

2.16 Aplicando SVM com K-fold

[240]:
```
metodo = 'SVMSELECT'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
↪0, 'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

svm = SVC()
svm.fit(x_train, y_train)

y_predict = svm.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 1.0
Recall: 1.0
Precisão: 1.0
F-Measure: 1.0
Indice Kappa: 1.0
Acuária Balanceada: 1.0
```

[241]:
```
# metodo = 'SVMSELECT'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler2[train_index], data_scaler2[test_index]
```

```
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     svm = SVC()
#     svm.fit(x_train, y_train)
#
#     y_predict = svm.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

[242]:
```
analise = './metricas.csv'
metricas = pd.read_csv(
    analise,
    )
metricas
```

[242]:

	Acurácia	Recall	Precisão	F1	Kappa	Acurácia Balanceada
KNN	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
Gauss	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
Tree	0.9922	0.9922	0.9931	0.9922	0.9916	0.9934
SVM	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
KNNSELECT	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
GaussSELECT	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
TreeSELECT	0.9844	0.9844	0.9845	0.9845	0.9833	0.9840
SVMSELECT	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000

dim128-classification

August 19, 2020

1 0. Introdução

Trabalho Clustering:

Aluno: Gabriel Luiz

Disciplina: Tópico em Aprendizado de Máquina

Objetivos :

- Escolha dois datasets rotulados.
- Realize a análise estatística, visualização e pré-processamento dos dados.
- Realize os experimentos criando duas bases de teste distintas:
- – considerando todos os atributos do dataset;
- – selecionando alguns atributos e descartando outros.
- Aplique três métodos de classificação distintos nas duas bases acima referentes a cada dataset.
- Para cada dataset, em cada uma das bases, analise os resultados segundo medidas de qualidade de classificação, usando índices de validação externa (acurácia, recall, precisão, F-measure, índice Kappa) e cruva ROC.
- Proponha uma maneira adicional de comparar os resultados obtidos além das medidas acima.
- Compare e interprete os resultados dos dois experimentos em cada dataset. Faça tabela com as medidas de validação

1.1 0.1 Dependências

Para realização da tarefa foram utilizados as seguintes bibliotecas:

[183]:
```
from datetime import datetime
import numpy as np
import pandas as pd
from sklearn.cluster import *
import seaborn as sns
from sklearn.preprocessing import StandardScaler
import matplotlib.pyplot as plt
from sklearn.feature_selection import SelectKBest
```

```
from sklearn.feature_selection import chi2
from sklearn.model_selection import train_test_split

# KFold
from sklearn.model_selection import KFold
import random

# Classificadores
from sklearn.neighbors import KNeighborsClassifier
from sklearn.naive_bayes import GaussianNB
from sklearn.tree import DecisionTreeClassifier
from sklearn.svm import SVC

#Metricas
from sklearn.metrics import accuracy_score
from sklearn.metrics import recall_score
from sklearn.metrics import precision_score
from sklearn.metrics import f1_score
from sklearn.metrics import cohen_kappa_score
from  sklearn.metrics  import  roc_auc_score
from sklearn.metrics import balanced_accuracy_score
```

2 1. Dados

Para realização das tarefas envolvidas neste relatório utilizou-se o arquivo **dim032.csv** que contém dados não descritos, onde foram feitos para a realização de clustering que se encontram no site: http://cs.uef.fi/sipu/datasets/

2.1 1.1 Carregamento do arquivo

[184]:
```
from clustering.labelMatch import rotulos, labelmatch
dataset = './dataset/dim128/dim128.csv'
clusters = './dataset/dim128/dim128pa.csv'
```

[185]:
```
data = pd.read_csv(
    dataset,
    header = None
    )

label = pd.read_csv(
    clusters,
    header = None
    )
```

[186]:
```
data.head()
```

[186]:

	0	1	2	3	4	5	6	7	8	9	…	118	119	120	121	\
0	145	142	131	135	208	209	65	128	183	131	…	199	218	182	53	
1	149	148	137	137	213	209	71	125	183	125	…	198	222	182	52	
2	151	144	135	132	210	208	67	124	183	128	…	198	218	182	52	
3	148	141	136	135	207	209	65	127	184	130	…	197	219	184	50	
4	146	145	136	135	208	212	70	130	185	129	…	199	217	182	52	

	122	123	124	125	126	127
0	144	198	93	34	99	79
1	148	198	97	35	99	78
2	144	196	93	38	101	78
3	144	198	92	36	101	82
4	148	198	95	36	96	80

[5 rows x 128 columns]

[187]:
```
data.describe()
```

[187]:

	0	1	2	3	4	\
count	1024.000000	1024.000000	1024.000000	1024.000000	1024.000000	
mean	125.248047	150.040039	134.053711	134.069336	118.694336	
std	51.254859	48.465458	49.652222	38.661577	54.941676	
min	31.000000	45.000000	42.000000	46.000000	35.000000	
25%	89.500000	129.500000	104.500000	100.750000	76.500000	
50%	117.000000	145.000000	142.000000	139.500000	111.000000	
75%	158.500000	191.000000	174.000000	167.000000	158.000000	
max	220.000000	225.000000	205.000000	195.000000	227.000000	

	5	6	7	8	9	…	\
count	1024.000000	1024.000000	1024.000000	1024.000000	1024.000000	…	
mean	145.112305	125.099609	117.110352	108.508789	126.273438	…	
std	44.562082	51.200904	48.900247	51.715931	50.317170	…	
min	65.000000	52.000000	41.000000	31.000000	41.000000	…	
25%	111.250000	66.000000	72.000000	68.000000	89.000000	…	
50%	143.000000	130.000000	116.000000	100.000000	121.500000	…	
75%	180.000000	171.250000	152.250000	137.250000	176.000000	…	
max	218.000000	207.000000	220.000000	207.000000	218.000000	…	

	118	119	120	121	122	\
count	1024.000000	1024.000000	1024.000000	1024.000000	1024.000000	
mean	145.520508	133.936523	130.793945	136.500000	136.348633	
std	54.379262	55.852890	58.455433	52.589374	51.880328	
min	34.000000	42.000000	41.000000	47.000000	30.000000	
25%	105.750000	90.750000	83.000000	103.500000	100.250000	
50%	150.500000	133.000000	111.500000	134.000000	133.000000	

```
75%     194.000000   187.000000   195.750000   184.500000   187.000000
max     223.000000   224.000000   222.000000   218.000000   218.000000

                123          124          125          126          127
count   1024.000000  1024.000000  1024.000000  1024.000000  1024.000000
mean     117.336914   123.756836    99.931641   110.326172   151.151367
std       60.981599    46.710213    49.196389    60.645574    49.358342
min       32.000000    25.000000    27.000000    30.000000    58.000000
25%       60.750000    94.000000    63.000000    54.750000   114.750000
50%      113.500000   124.000000    87.500000    98.000000   179.500000
75%      181.250000   159.000000   128.250000   168.000000   190.000000
max      209.000000   210.000000   194.000000   215.000000   204.000000

[8 rows x 128 columns]
```

3 2. Pré-processamento

Validações efetivadas:

- 1. Dados faltantes representados por "NaN"
- 2. Dados que não possuem valores númericos

[188]:
```
# data.isna().sum()
```

[189]:
```
# for col in data:
    # print(col, data[col].unique())
```

2.1 Conclusão:

- Os dados não possuem a necessidade de pré-processamento visto que já estão todos com valores validos

3.0.1 2.3 Análise estatística

[190]:
```
data.corr()
```

[190]:
```
           0         1         2         3         4         5         6    \
0     1.000000 -0.298556  0.099976  0.022622  0.147617  0.121319 -0.126459
1    -0.298556  1.000000 -0.185263  0.432802 -0.292705  0.061192 -0.019780
2     0.099976 -0.185263  1.000000  0.067625  0.362365 -0.028879  0.080121
3     0.022622  0.432802  0.067625  1.000000  0.099326 -0.144059 -0.112927
4     0.147617 -0.292705  0.362365  0.099326  1.000000  0.293487 -0.131999
..         …         …         …         …         …         …
123   0.034045  0.016683 -0.044062 -0.358739  0.033921  0.005289  0.050475
```

```
124  0.463972 -0.548772  0.567061 -0.241791  0.189920 -0.258597  0.129884
125 -0.023602  0.217301 -0.184789  0.213103 -0.551513 -0.268762  0.541192
126 -0.188079  0.429549 -0.021832 -0.361639  0.109259  0.058695  0.386794
127  0.311024 -0.073918  0.222362 -0.177917 -0.318805  0.066725  0.368015

           7         8         9    …       118       119       120  \
0    0.467975  0.279398 -0.138266  … -0.357315 -0.012444  0.125286
1    0.016283 -0.213111  0.143765  … -0.173967  0.247016  0.633308
2    0.012888  0.007419  0.235775  …  0.223319 -0.231223 -0.192837
3    0.266907 -0.429601 -0.028823  … -0.416790 -0.262267  0.586108
4   -0.170449  0.577666 -0.063625  …  0.227436 -0.035686  0.014784
..        …         …         …  …       …         …         …
123 -0.220242  0.284786 -0.384904  … -0.014952  0.285386 -0.044914
124  0.046233  0.049035  0.115393  …  0.125422 -0.340187 -0.507953
125  0.318943 -0.447063  0.044297  … -0.288177  0.100666  0.075201
126 -0.197502  0.433910  0.145782  …  0.329098  0.320879 -0.103570
127  0.154835  0.012821  0.257718  …  0.127201  0.133552 -0.133041

           121       122       123       124       125       126       127
0    0.218881 -0.253469  0.034045  0.463972 -0.023602 -0.188079  0.311024
1    0.059660  0.505386  0.016683 -0.548772  0.217301  0.429549 -0.073918
2    0.184547  0.445270 -0.044062  0.567061 -0.184789 -0.021832  0.222362
3   -0.148362  0.295559 -0.358739 -0.241791  0.213103 -0.361639 -0.177917
4   -0.217203  0.237352  0.033921  0.189920 -0.551513  0.109259 -0.318805
..        …         …         …         …         …         …         …
123  0.278613  0.218825  1.000000 -0.225108 -0.049457  0.195657 -0.273943
124  0.413947 -0.233779 -0.225108  1.000000 -0.204440 -0.045870  0.515130
125 -0.131423 -0.175185 -0.049457 -0.204440  1.000000  0.001906  0.355830
126  0.085155  0.183157  0.195657 -0.045870  0.001906  1.000000  0.143927
127  0.203967 -0.040931 -0.273943  0.515130  0.355830  0.143927  1.000000

[128 rows x 128 columns]
```

[191]:
```
df = data
df = df.assign(label = label)
test = df[[0, 1, 2, 3, 'label']]
test
```

[191]:
```
        0    1    2    3  label
0     145  142  131  135      1
1     149  148  137  137      1
2     151  144  135  132      1
3     148  141  136  135      1
4     146  145  136  135      1
…     …    …    …    …      …
1019  172   55  146   85     16
1020  172   54  147   91     16
```

```
1021   179    47   149    86      16
1022   176    50   148    86      16
1023   172    55   145    92      16

[1024 rows x 5 columns]
```

[ ]:
```
sns.pairplot(df, diag_kind="kde",hue='label')
```

[192]:
```
sns.pairplot(test, diag_kind="kde",hue='label')
```

[192]:
```
<seaborn.axisgrid.PairGrid at 0x7f5b5c93aa20>
```

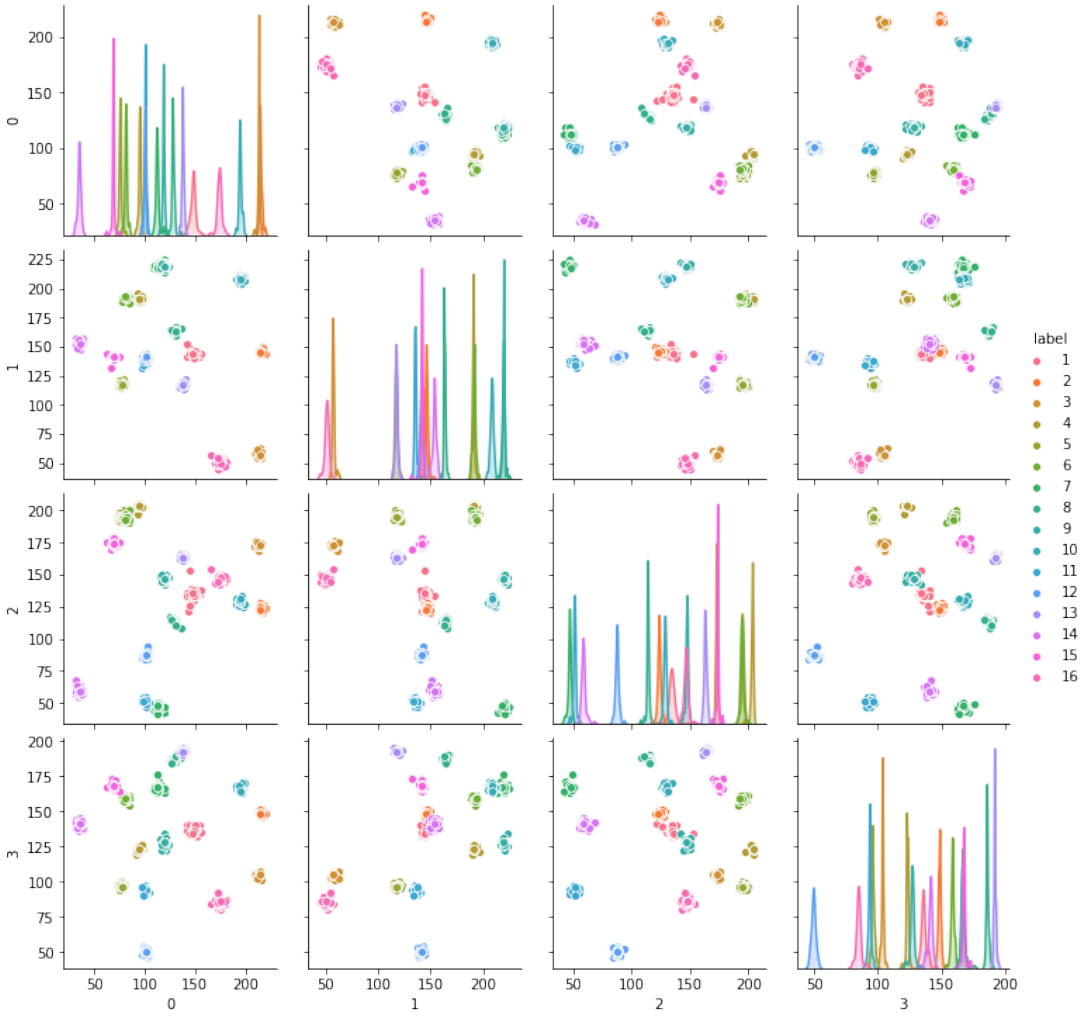

3.0.2 2.4 Escalonando

Para aplicação dos algoritmos escalona-se os dados afim de parametriza-los num certo intervalor (-1 a 1)

[193]:
```
data = data.to_numpy()
scaler = StandardScaler().fit(data)
data_scaler = scaler.transform(data)
```

[194]:
```
# data_scaled = pd.DataFrame(data_scaler)
# data_scaled.head()
```

[195]:
```
data_results = np.array(label[0].tolist())
for idx, value in np.ndenumerate(data_results):
    data_results[idx] = value - 1
```

3.0.3 2.5 Plotando boxsplot

Pelo boxsplot é possivel visualizar que há alguns outliers.

[196]:
```
# data_scaled.plot(kind = 'box', figsize=(30,10), rot=90, )
```

3.1 3.2 Selecionando atributos do dataset

[197]:
```
data_reduzida = pd.DataFrame(SelectKBest(chi2, k=30).fit_transform(data, label))
data_reduzida.shape
data_reduzida = data_reduzida.to_numpy()

data_scaler2 = scaler.fit_transform(X = data_reduzida)
```

[198]:
```
# data_scaled2 = pd.DataFrame(data_scaler2)
# data_scaled2.head()
```

3.2 Classificando

3.3 Funções necessárias

[199]:
```
def calcula_metricas(metricas, y_test, y_predict):
    metricas['acc'] += (accuracy_score(y_test, y_predict))
    metricas['recall'] += (recall_score(y_test, y_predict, average='micro'))
    metricas['precision'] += (precision_score(y_test, y_predict,␣
 ↪average='macro'))
    metricas['f1'] += f1_score(y_test, y_predict, average='weighted')
    # metricas['roc'] += roc_auc_score(y_test, y_predict)
```

```
    metricas['kappa'] += cohen_kappa_score(y_test, y_predict)
    metricas['balanced_acc'] += balanced_accuracy_score(y_test, y_predict)
```

[200]:
```
def save_metricas(name, metricas):
    f = open(name, 'w')
    f.write('Acuária:' + str(metricas['acc']) + '\n')
    f.write('Recall:' + str(metricas['recall']) + '\n')
    f.write('Precisão:' + str(metricas['precision']) + '\n')
    f.write('F-Measure:' + str(metricas['f1']) + '\n')
    # f.write('Curva Roc:' + str(metricas['roc']) + '\n')
    f.write('Indice Kappa:' + str(metricas['kappa']) + '\n')
    f.write('Acuária Balanceada:' + str(metricas['balanced_acc']) + '\n')
    f.close()
```

[201]:
```
def show_metricas(metricas):
    print('Acuária:', metricas['acc'])
    print('Recall:', metricas['recall'])
    print('Precisão:', metricas['precision'])
    print('F-Measure:', metricas['f1'])
    # print('Curva Roc:', metricas['roc'])
    print('Indice Kappa:', metricas['kappa'])
    print('Acuária Balanceada:', metricas['balanced_acc'])
```

[202]:
```
def write_metricas(name_file, metricas, metodo):
    f = open(name_file, "a")
    f.write(metodo + ',')
    f.write(str(round(metricas['acc'],4)) + ',')
    f.write(str(round(metricas['recall'],4)) + ',')
    f.write(str(round(metricas['precision'],4)) + ',')
    f.write(str(round(metricas['f1'],4)) + ',')
    # f.write(str(round(metricas['roc'],4)) + ';')
    f.write(str(round(metricas['kappa'],4)) + ',')
    f.write(str(round(metricas['balanced_acc'],4)) + '\n')
    f.close()
```

3.4 DataFrame Completo

[203]:
```
# TODO change split function
kf = KFold(n_splits=2, shuffle=True, random_state=random.randint(0, 10))
data_kfold = kf.split(data)

train = []
test = []

for train_index, test_index in data_kfold:
    train.append(train_index)
```

```
    test.append(test_index)
```

[204]:
```
name_file = 'metricas.csv'

# Roc;
f = open(name_file, "w")
f.write('Acurácia,Recall,Precisão,F1,Kappa,Acurácia Balanceada\n')
f.close()
```

3.5 Aplicando KNN com train_test_split

kfold (era k-fold)

K Nearest neighbor (K-ésimo Vizinho mais Próximo)

[205]:
```
# 'roc': 0,
metodo = 'KNN'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'kappa': 0,␣
 ↪'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

neigh = KNeighborsClassifier(n_neighbors=10)
neigh.fit(x_train, y_train)

y_predict = neigh.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 1.0
Recall: 1.0
Precisão: 1.0
F-Measure: 1.0
Indice Kappa: 1.0
Acuária Balanceada: 1.0
```

[206]:
```
# # 'roc': 0,
# metodo = 'KNN'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'kappa': 0,␣
 ↪'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler[train_index], data_scaler[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
```

```
#
#     neigh = KNeighborsClassifier(n_neighbors=100)
#     neigh.fit(x_train, y_train)
#
#     y_predict = neigh.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

3.6 Aplicando GaussianNB

(Classificador Gaussiano Naïve Bayesiano)

[207]:
```
metodo = 'Gauss'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
 ↪0, 'balanced_acc': 0}


x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

gauss = GaussianNB()
gauss.fit(x_train, y_train)

y_predict = gauss.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 1.0
Recall: 1.0
Precisão: 1.0
F-Measure: 1.0
Indice Kappa: 1.0
Acuária Balanceada: 1.0
```

[208]:
```
# metodo = 'Gauss'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
 ↪ 0, 'balanced_acc': 0}
#
```

```
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler[train_index], data_scaler[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     gauss = GaussianNB()
#     gauss.fit(x_train, y_train)
#
#     y_predict = gauss.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

3.7 Aplicando DecisionTreeClassifier

Árvores de Decisão

[209]:
```
metodo = 'Tree'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
 ↪0, 'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

tree = DecisionTreeClassifier()
tree.fit(x_train, y_train)

y_predict = tree.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 0.99609375
Recall: 0.99609375
Precisão: 0.9955357142857143
F-Measure: 0.996103083930705
Indice Kappa: 0.9958187015108207
Acuária Balanceada: 0.99609375
```

[210]:
```
# metodo = 'Tree'
```

```
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
 ↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler[train_index], data_scaler[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     tree = DecisionTreeClassifier()
#     tree.fit(x_train, y_train)
#
#     y_predict = tree.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

3.8 Aplicando SVM

Máquinas de Vetores de Suporte (SVMs)

[211]:
```
metodo = 'SVM'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
 ↪0, 'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

svm = SVC()
svm.fit(x_train, y_train)

y_predict = svm.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 1.0
Recall: 1.0
Precisão: 1.0
F-Measure: 1.0
Indice Kappa: 1.0
Acuária Balanceada: 1.0
```

[212]:
```
# metodo = 'SVM'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
 ↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler[train_index], data_scaler[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     sum = SVC()
#     sum.fit(x_train, y_train)
#
#     y_predict = sum.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

3.9 DataFrame Selecionado

3.10 Aplicando

[213]:
```
kf = KFold(n_splits=2, shuffle=True, random_state=random.randint(0, 10))
data_kfold = kf.split(data_scaler2)

train = []
test = []

for train_index, test_index in data_kfold:
    train.append(train_index)
    test.append(test_index)
```

3.11 Aplicando KNN

[214]:
```
metodo = 'KNNSELECT'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
 ↪0, 'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

neigh = KNeighborsClassifier(n_neighbors=10)
```

```
neigh.fit(x_train, y_train)

y_predict = neigh.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 1.0
Recall: 1.0
Precisão: 1.0
F-Measure: 1.0
Indice Kappa: 1.0
Acuária Balanceada: 1.0
```

[215]:
```
# metodo = 'KNNSELECT'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
 ↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler2[train_index], data_scaler2[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     neigh = KNeighborsClassifier(n_neighbors=20)
#     neigh.fit(x_train, y_train)
#
#     y_predict = neigh.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

3.12 Aplicando GaussianNB

[216]:
```
metodo = 'GaussSELECT'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
 ↪0, 'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

gauss = GaussianNB()
```

```
gauss.fit(x_train, y_train)

y_predict = gauss.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 1.0
Recall: 1.0
Precisão: 1.0
F-Measure: 1.0
Indice Kappa: 1.0
Acuária Balanceada: 1.0
```

[217]:
```
# metodo = 'GaussSELECT'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
 ↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler2[train_index], data_scaler2[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     gauss = GaussianNB()
#     gauss.fit(x_train, y_train)
#
#     y_predict = gauss.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

3.13 Aplicando DecisionTreeClassifier

[218]:
```
metodo = 'TreeSELECT'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
 ↪0, 'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

tree = DecisionTreeClassifier()
```

```
tree.fit(x_train, y_train)

y_predict = tree.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 0.98828125
Recall: 0.98828125
Precisão: 0.9872596153846154
F-Measure: 0.9883769914215685
Indice Kappa: 0.9874741082641528
Acuária Balanceada: 0.9899305555555555
```

[219]:
```
# metodo = 'TreeSELECT'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
 ↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler2[train_index], data_scaler2[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     tree = DecisionTreeClassifier()
#     tree.fit(x_train, y_train)
#
#     y_predict = tree.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

3.14 Aplicando SVM

[220]:
```
metodo = 'SVMSELECT'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
 ↪0, 'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

svm = SVC()
```

```
svm.fit(x_train, y_train)

y_predict = svm.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 1.0
Recall: 1.0
Precisão: 1.0
F-Measure: 1.0
Indice Kappa: 1.0
Acuária Balanceada: 1.0
```

[221]:
```
# metodo = 'SVMSELECT'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
 ↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler2[train_index], data_scaler2[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     svm = SVC()
#     svm.fit(x_train, y_train)
#
#     y_predict = svm.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

[222]:
```
analise = './metricas.csv'
metricas = pd.read_csv(
    analise,
    )
metricas
```

[222]:

	Acurácia	Recall	Precisão	F1	Kappa	Acurácia Balanceada
KNN	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
Gauss	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
Tree	0.9961	0.9961	0.9955	0.9961	0.9958	0.9961

SVM	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
KNNSELECT	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
GaussSELECT	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000
TreeSELECT	0.9883	0.9883	0.9873	0.9884	0.9875	0.9899
SVMSELECT	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000

iris-classification

August 19, 2020

1 0. Introdução

Trabalho Clustering:

Aluno: Gabriel Luiz

Disciplina: Tópico em Aprendizado de Máquina

Objetivos :

- Escolha dois datasets rotulados.
- Realize a análise estatística, visualização e pré-processamento dos dados.
- Realize os experimentos criando duas bases de teste distintas:
- – considerando todos os atributos do dataset ;
- – selecionando alguns atributos e descartando outros;
- Aplique três métodos de clustering distintos nas duas bases acima.
- Para cada dataset , em cada uma das bases, analise os resultados segundo medidas de qualidade de clustering , usando índices de validação interna (SSW, SSB, silhueta, Calinski-Harabasz, Dunn e Davis-Bouldin) e externa (pureza, entropia, acurácia, F-measure , ARI, NMI).
- Proponha uma maneira adicional de comparar os resultados obtidos além das medidas acima.
- Compare e interprete os resultados dos dois experimentos em cada dataset

1.1 0.1 Dependências

Para realização da tarefa foram utilizados as seguintes bibliotecas:

[96]:
```
from datetime import datetime
import numpy as np
import pandas as pd
from sklearn import preprocessing
from sklearn.cluster import *
import seaborn as sns
from sklearn.preprocessing import StandardScaler
import matplotlib.pyplot as plt
```

```
from sklearn.feature_selection import SelectKBest
from sklearn.feature_selection import chi2
from sklearn.model_selection import train_test_split

# KFold
from sklearn.model_selection import KFold
import random

# Classificadores
from sklearn.neighbors import KNeighborsClassifier
from sklearn.naive_bayes import GaussianNB
from sklearn.tree import DecisionTreeClassifier
from sklearn.svm import SVC

#Metricas
from sklearn.metrics import accuracy_score
from sklearn.metrics import recall_score
from sklearn.metrics import precision_score
from sklearn.metrics import f1_score
from sklearn.metrics import cohen_kappa_score
from  sklearn.metrics  import  roc_auc_score
from sklearn.metrics import balanced_accuracy_score

from sklearn.datasets import load_iris
```

2 1. Dados

Para realização das tarefas envolvidas neste relatório utilizou-se o arquivo **dim128.csv** que contém dados não descritos, onde foram feitos para a realização de clustering que se encontram no site: http://cs.uef.fi/sipu/datasets/

2.1 1.1 Carregamento do arquivo

[97]:
```
(data, label) = load_iris(return_X_y=True, as_frame = True)
```

[98]:
```
scaler = preprocessing.StandardScaler()
data_scaler = scaler.fit_transform(X = data)

data_results = np.array(label)

## 3.2 Selecionando atributos do dataset
```

[99]:
```
data_reduzida = pd.DataFrame(SelectKBest(chi2, k=2).fit_transform(data, label))
data_reduzida.shape
```

```
data_reduzida = data_reduzida.to_numpy()

data_scaler2 = scaler.fit_transform(X = data_reduzida)
```

[100]:
```
# data_scaled2 = pd.DataFrame(data_scaler2)
# data_scaled2.head()
```

[126]:
```
df = data
df = df.assign(label = label)
```

[127]:
```
sns.pairplot(df, diag_kind="kde",hue='label')
```

[127]: <seaborn.axisgrid.PairGrid at 0x7ff65902ae80>

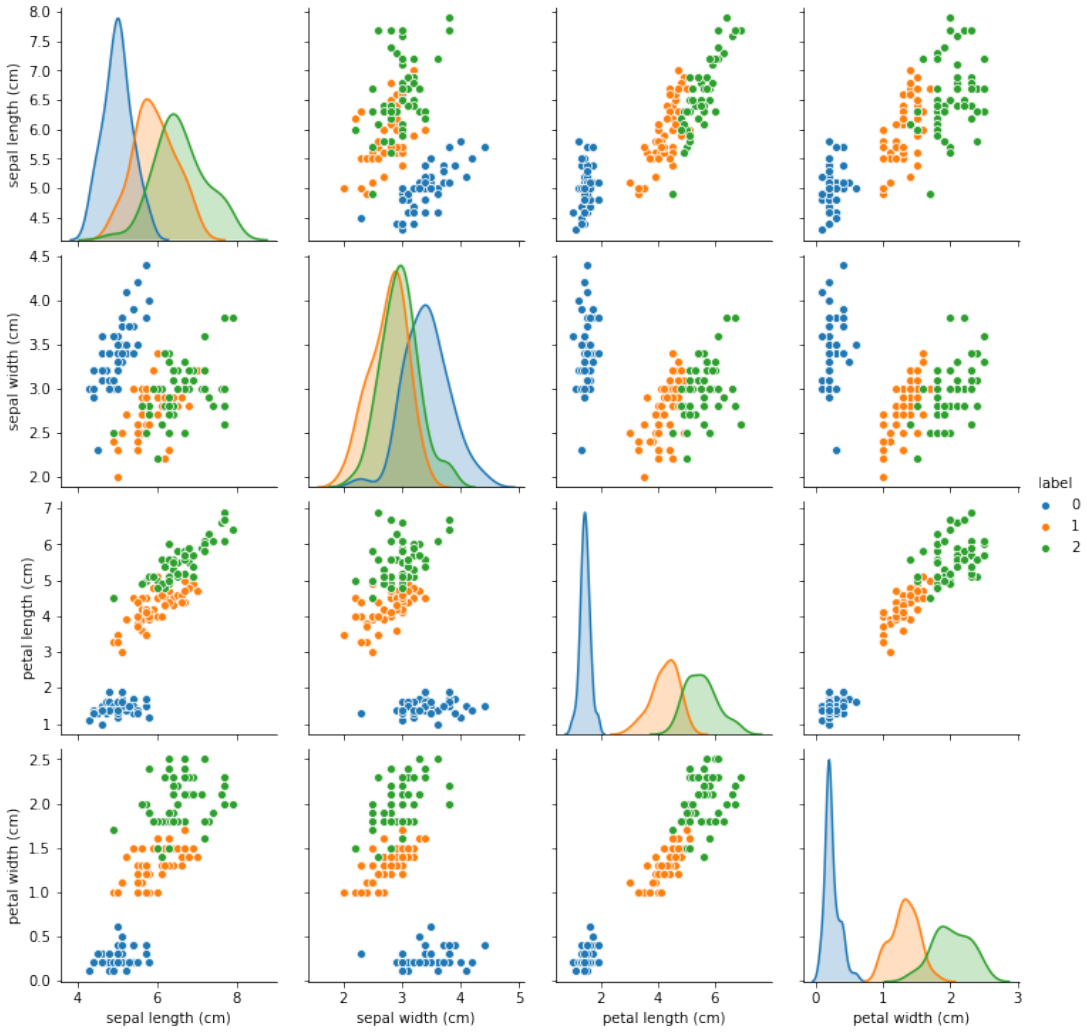

2.2 Classificando

2.3 Funções necessárias

[101]:
```
def calcula_metricas(metricas, y_test, y_predict):
    metricas['acc'] += (accuracy_score(y_test, y_predict))
    metricas['recall'] += (recall_score(y_test, y_predict, average='micro'))
    metricas['precision'] += (precision_score(y_test, y_predict,␣
 ↪average='macro'))
    metricas['f1'] += f1_score(y_test, y_predict, average='weighted')
    # metricas['roc'] += roc_auc_score(y_test, y_predict)
    metricas['kappa'] += cohen_kappa_score(y_test, y_predict)
    metricas['balanced_acc'] += balanced_accuracy_score(y_test, y_predict)
```

[102]:
```
def save_metricas(name, metricas):
    f = open(name, 'w')
    f.write('Acuária:' + str(metricas['acc']) + '\n')
    f.write('Recall:' + str(metricas['recall']) + '\n')
    f.write('Precisão:' + str(metricas['precision']) + '\n')
    f.write('F-Measure:' + str(metricas['f1']) + '\n')
    # f.write('Curva Roc:' + str(metricas['roc']) + '\n')
    f.write('Indice Kappa:' + str(metricas['kappa']) + '\n')
    f.write('Acuária Balanceada:' + str(metricas['balanced_acc']) + '\n')
    f.close()
```

[103]:
```
def show_metricas(metricas):
    print('Acuária:', metricas['acc'])
    print('Recall:', metricas['recall'])
    print('Precisão:', metricas['precision'])
    print('F-Measure:', metricas['f1'])
    # print('Curva Roc:', metricas['roc'])
    print('Indice Kappa:', metricas['kappa'])
    print('Acuária Balanceada:', metricas['balanced_acc'])
```

[104]:
```
def write_metricas(name_file, metricas, metodo):
    f = open(name_file, "a")
    f.write(metodo + ',')
    f.write(str(metricas['acc']) + ',')
    f.write(str(metricas['recall']) + ',')
    f.write(str(metricas['precision']) + ',')
    f.write(str(metricas['f1']) + ',')
    # f.write(str(round(metricas['roc'],4)) + ';')
    f.write(str(metricas['kappa']) + ',')
    f.write(str(metricas['balanced_acc']) + '\n')
    f.close()
```

2.4 Aplicando KNN com K-fold

2.5 DataFrame Cru

[105]:
```
formato = 'Cru'

folds_value = 16
```

[106]:
```
# TODO change split function
kf = KFold(n_splits=2, shuffle=True, random_state=random.randint(0, 10))
data_kfold = kf.split(data)

train = []
test = []

for train_index, test_index in data_kfold:
    train.append(train_index)
    test.append(test_index)
```

[107]:
```
name_file = 'metricas.csv'

# Roc;
f = open(name_file, "w")
f.write('Acurácia,Recall,Precisão,F1,Kappa,Acurácia Balanceada\n')
f.close()
```

2.6 Aplicando KNN com K-fold

[108]:
```
# 'roc': 0,
metodo = 'KNN'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'kappa': 0,␣
 ↪'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

neigh = KNeighborsClassifier(n_neighbors=10)
neigh.fit(x_train, y_train)

y_predict = neigh.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 1.0
Recall: 1.0
Precisão: 1.0
F-Measure: 1.0
Indice Kappa: 1.0
Acuária Balanceada: 1.0
```

[109]:
```
# # 'roc': 0,
# metodo = 'KNN'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'kappa': 0,␣
 ↪'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler[train_index], data_scaler[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     neigh = KNeighborsClassifier(n_neighbors=100)
#     neigh.fit(x_train, y_train)
#
#     y_predict = neigh.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

2.7 Aplicando GaussianNB com K-fold

[110]:
```
metodo = 'Gauss'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
 ↪0, 'balanced_acc': 0}


x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

gauss = GaussianNB()
gauss.fit(x_train, y_train)

y_predict = gauss.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
```

```
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 0.9473684210526315
Recall: 0.9473684210526315
Precisão: 0.9458874458874459
F-Measure: 0.9473684210526315
Indice Kappa: 0.9206680584551148
Acuária Balanceada: 0.9458874458874459
```

[111]:
```
# metodo = 'Gauss'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
 ↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler[train_index], data_scaler[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     gauss = GaussianNB()
#     gauss.fit(x_train, y_train)
#
#     y_predict = gauss.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

2.8 Aplicando DecisionTreeClassifier com K-fold

[112]:
```
metodo = 'Tree'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
 ↪0, 'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

tree = DecisionTreeClassifier()
tree.fit(x_train, y_train)

y_predict = tree.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
```

```
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 1.0
Recall: 1.0
Precisão: 1.0
F-Measure: 1.0
Indice Kappa: 1.0
Acuária Balanceada: 1.0
```

[113]:
```
# metodo = 'Tree'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
 ↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler[train_index], data_scaler[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     tree = DecisionTreeClassifier()
#     tree.fit(x_train, y_train)
#
#     y_predict = tree.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

2.9 Aplicando SVM com K-fold

[114]:
```
metodo = 'SVM'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
 ↪0, 'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

svm = SVC()
svm.fit(x_train, y_train)

y_predict = svm.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
```

```
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 0.9473684210526315
Recall: 0.9473684210526315
Precisão: 0.9555555555555556
F-Measure: 0.9468557758031441
Indice Kappa: 0.9208333333333334
Acuária Balanceada: 0.9444444444444445
```

[115]:
```
# metodo = 'SVM'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
 ↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler[train_index], data_scaler[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     svm = SVC()
#     svm.fit(x_train, y_train)
#
#     y_predict = svm.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

2.10 DataFrame Selecionado

2.11 Aplicando

[116]:
```
kf = KFold(n_splits=2, shuffle=True, random_state=random.randint(0, 10))
data_kfold = kf.split(data_scaler2)

train = []
test = []

for train_index, test_index in data_kfold:
    train.append(train_index)
    test.append(test_index)
```

2.12 Aplicando KNN com K-fold

[117]:
```
metodo = 'KNNSELECT'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
↪0, 'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

neigh = KNeighborsClassifier(n_neighbors=10)
neigh.fit(x_train, y_train)

y_predict = neigh.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 1.0
Recall: 1.0
Precisão: 1.0
F-Measure: 1.0
Indice Kappa: 1.0
Acuária Balanceada: 1.0
```

[118]:
```
# metodo = 'KNNSELECT'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler2[train_index], data_scaler2[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     neigh = KNeighborsClassifier(n_neighbors=20)
#     neigh.fit(x_train, y_train)
#
#     y_predict = neigh.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

2.13 Aplicando GaussianNB com K-fold

[119]:
```
metodo = 'GaussSELECT'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
 ↪0, 'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

gauss = GaussianNB()
gauss.fit(x_train, y_train)

y_predict = gauss.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 0.9473684210526315
Recall: 0.9473684210526315
Precisão: 0.9440559440559442
F-Measure: 0.9473684210526315
Indice Kappa: 0.9206680584551148
Acuária Balanceada: 0.9440559440559442
```

[120]:
```
# metodo = 'GaussSELECT'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
 ↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler2[train_index], data_scaler2[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     gauss = GaussianNB()
#     gauss.fit(x_train, y_train)
#
#     y_predict = gauss.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

2.14 Aplicando DecisionTreeClassifier com K-fold

[121]:
```
metodo = 'TreeSELECT'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
↪0, 'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

tree = DecisionTreeClassifier()
tree.fit(x_train, y_train)

y_predict = tree.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 0.9473684210526315
Recall: 0.9473684210526315
Precisão: 0.9500891265597149
F-Measure: 0.9473684210526315
Indice Kappa: 0.9186295503211992
Acuária Balanceada: 0.9500891265597149
```

[122]:
```
# metodo = 'TreeSELECT'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler2[train_index], data_scaler2[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     tree = DecisionTreeClassifier()
#     tree.fit(x_train, y_train)
#
#     y_predict = tree.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

2.15 Aplicando SVM com K-fold

[123]:
```
metodo = 'SVMSELECT'
metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':␣
↪0, 'balanced_acc': 0}

x_train, x_test, y_train, y_test = train_test_split(data_scaler, data_results)

svm = SVC()
svm.fit(x_train, y_train)

y_predict = svm.predict(x_test)

calcula_metricas(metricas, y_test, y_predict)

show_metricas(metricas)
write_metricas(name_file, metricas, metodo)
```

```
Acuária: 0.9473684210526315
Recall: 0.9473684210526315
Precisão: 0.9555555555555556
F-Measure: 0.947223828802776
Indice Kappa: 0.9208333333333334
Acuária Balanceada: 0.9523809523809524
```

[124]:
```
# metodo = 'SVMSELECT'
# metricas = {'acc': 0, 'recall': 0, 'precision': 0, 'f1': 0, 'roc': 0, 'kappa':
↪ 0, 'balanced_acc': 0}
#
# for train_index, test_index in zip(train, test):
#     x_train, x_test = data_scaler2[train_index], data_scaler2[test_index]
#     y_train, y_test = data_results[train_index], data_results[test_index]
#
#     svm = SVC()
#     svm.fit(x_train, y_train)
#
#     y_predict = svm.predict(x_test)
#
#     calcula_metricas(metricas, y_test, y_predict)
#
# for metrica, value in metricas.items():
#     metricas[metrica] = value/10
#
# show_metricas(metricas)
# write_metricas(name_file, metricas, metodo)
```

[125]:
```
analise = './metricas.csv'
metricas = pd.read_csv(
    analise,
    )
metricas
```

[125]:

	Acurácia	Recall	Precisão	F1	Kappa	\
KNN	1.000000	1.000000	1.000000	1.000000	1.000000	
Gauss	0.947368	0.947368	0.945887	0.947368	0.920668	
Tree	1.000000	1.000000	1.000000	1.000000	1.000000	
SVM	0.947368	0.947368	0.955556	0.946856	0.920833	
KNNSELECT	1.000000	1.000000	1.000000	1.000000	1.000000	
GaussSELECT	0.947368	0.947368	0.944056	0.947368	0.920668	
TreeSELECT	0.947368	0.947368	0.950089	0.947368	0.918630	
SVMSELECT	0.947368	0.947368	0.955556	0.947224	0.920833	

	Acurácia Balanceada
KNN	1.000000
Gauss	0.945887
Tree	1.000000
SVM	0.944444
KNNSELECT	1.000000
GaussSELECT	0.944056
TreeSELECT	0.950089
SVMSELECT	0.952381